

Engenharia de Prompts: comunicação com modelos de IA

Claude & ChatGPT

Evento	III InterPET — IFTM (Instituto Federal do Triângulo Mineiro)
Data	15 de abril de 2026
Local	Ituiutaba, MG
Palestrante	Dr. André Luiz França Batista
Instituição	IFTM Campus Ituiutaba

Engenharia de Prompts: comunicação com modelos de IA

III InterPET — IFTM (Instituto Federal do Triângulo Mineiro)

17 15 de abril de 2026 · Ituiutaba, MG

 Palestrante: Dr. André Luiz França Batista

Ferramentas de referência: Claude e ChatGPT

Sumário

1. [O que é Engenharia de Prompts?](#)
2. [Por que prompts vagos falham?](#)
3. [Técnica 1 — Few-Shot Prompting / Exemplos Guiados](#)
4. [Técnica 2 — Chain of Verification / Cadeia de Verificação](#)
5. [Técnica 3 — Memory Injection / Injeção de Memória](#)
6. [Técnica 4 — Reverse Prompting / Prompt Reverso](#)
7. [Técnica 5 — Constrain Cascade / Cascata de Restrições](#)
8. [Técnica 6 — Verification Loop / Laço de Verificação](#)
9. [Técnica 7 — Técnica KERNEL](#)
10. [Boas Práticas Consolidadas](#)
11. [Claude x ChatGPT: como as técnicas se aplicam](#)

1. O que é Engenharia de Prompts?

Um **prompt** é toda instrução ou entrada de texto que você envia a uma inteligência artificial generativa (IA generativa). É a única interface entre você e o modelo — tudo o que a IA produz parte diretamente do que ela recebe.

Engenharia de Prompts (*Prompt Engineering*) é a prática de escrever prompts de forma intencional, estruturada e estratégica, com o objetivo de obter respostas mais precisas, úteis e confiáveis.

Um princípio clássico da computação resume bem a ideia central:

"Garbage in, garbage out" — entra lixo, sai lixo.

O inverso também é verdadeiro: quanto mais claro, contextualizado e bem estruturado for o seu prompt, melhor será a resposta gerada. A IA não lê mentes — ela processa exatamente o que recebe. A responsabilidade pela qualidade da resposta começa em quem formula a pergunta.

2. Por que prompts vagos falham?

Considere o seguinte exemplo:

****Prompt vago:****

> **"Faça um site bonito."**

Este prompt deixa sem resposta perguntas fundamentais:

- Bonito para quem? Qual é o público-alvo?
- Qual é o objetivo do site?
- Que tecnologia deve ser usada?
- Quais seções devem existir?
- Qual é o prazo e o escopo esperado?

A IA vai responder — ela sempre responde. Mas o resultado provavelmente não corresponderá ao que você tinha em mente, porque **o que estava na sua cabeça nunca foi dito**.

****Prompt estruturado:****

> **"Crie o HTML de uma landing page para uma cafeteria chamada Moinho. Público: jovens de 18 a 30 anos. Cores: marrom e bege. Seções obrigatórias: apresentação, cardápio e contato. Sem frameworks externos."**

A diferença está em quatro elementos: **intenção clara**, **contexto**, **restrições** e **formato esperado**. Esses quatro elementos são a base de qualquer bom prompt — e estão detalhados na Técnica 7 (KERNEL).

3. Técnica 1 — Few-Shot Prompting / Exemplos Guiados

Definição

Few-Shot Prompting (Exemplos Guiados) consiste em fornecer exemplos do resultado esperado dentro do próprio prompt, antes de fazer a solicitação principal. Em vez de apenas descrever o que você quer, você mostra.

O termo "shot" significa "exemplo" neste contexto. A variação *Zero-Shot* é quando nenhum exemplo é fornecido — você apenas descreve a tarefa. O *Few-Shot* inclui de dois a cinco exemplos que demonstram o padrão desejado.

Quando usar

- Quando a tarefa exige um formato específico e bem definido
- Quando o tom, o estilo ou a estrutura da resposta importam tanto quanto o conteúdo

- Quando respostas genéricas anteriores não atenderam suas expectativas

Como funciona

Modelos de linguagem aprendem padrões. Ao ver exemplos, o modelo identifica: vocabulário, estrutura, nível de formalidade, comprimento e estilo — e os replica com precisão na resposta solicitada.

****Antes — Zero-Shot vago:****

> `*"Escreva títulos criativos para artigos de blog."*`

O modelo não sabe: qual o tom? Deve incluir números? Há subtítulo? Qual é o assunto?

****Depois — Few-Shot:****

> `*"Escreva títulos para artigos de blog seguindo este padrão:*`

>

> `*Exemplo 1: '5 hábitos que destroem sua produtividade (e como eliminá-los) '*`

> `*Exemplo 2: 'Por que você estuda muito e aprende pouco – e o que fazer'*`

> `*Exemplo 3: 'O erro que 90% das pessoas cometem ao tomar decisões importantes'*`

>

> `*Agora crie 3 títulos sobre saúde mental universitária seguindo o mesmo padrão."*`

O modelo aprende com os exemplos que os títulos devem ter: tom direto, número ou dado de impacto, e uma promessa de solução ou revelação.

4. Técnica 2 — Chain of Verification / Cadeia de Verificação

Definição

Chain of Verification (Cadeia de Verificação) é uma técnica que instrui a IA a verificar suas próprias afirmações antes de apresentar a resposta final. O modelo gera uma resposta inicial, lista as principais afirmações contidas nela, verifica cada uma e corrige o que for impreciso.

Quando usar

- Respostas que envolvem fatos, datas, nomes ou dados que precisam de precisão
- Resumos de textos longos onde erros de interpretação podem passar despercebidos
- Análises e recomendações que serão usadas como base para decisões

O problema que resolve: alucinações

Alucinação (*hallucination*) é o termo técnico para quando uma IA generativa produz informações incorretas com alto grau de confiança. Isso acontece porque o modelo gera texto estatisticamente plausível — não necessariamente verdadeiro. A Cadeia de Verificação reduz significativamente esse problema ao forçar uma etapa de revisão interna antes da entrega.

****Antes:****

> `"Quais são os principais filósofos iluministas e suas ideias?"`

A IA responde com confiança, mas pode errar datas, confundir obras entre autores ou atribuir ideias incorretamente.

****Depois:****

> `"Liste os principais filósofos iluministas e suas ideias centrais."`

>

> `"Em seguida, para cada filósofo citado, verifique se o nome, o período histórico e as obras mencionadas estão corretos."`

>

> `"Se encontrar alguma imprecisão, corrija antes de apresentar a resposta final."`

A própria IA audita o conteúdo que produziu. O resultado chega mais confiável — embora a verificação humana em fontes primárias continue sendo recomendada para informações críticas.

5. Técnica 3 — Memory Injection / Injeção de Memória

Definição

Memory Injection (Injeção de Memória) é a prática de carregar contexto relevante no início de uma conversa para que a IA o utilize durante toda a sessão. Funciona como um "briefing permanente" entregue ao modelo antes de qualquer tarefa.

O problema que resolve

Por padrão, IAs generativas não têm memória entre sessões distintas. Cada nova conversa começa do zero. Sem contexto injetado, o modelo não sabe quem você é, o que você faz, qual é seu estilo ou quais são suas preferências recorrentes.

Quando usar

- Fluxos de trabalho repetitivos onde você sempre precisa das mesmas informações de contexto

- Projetos longos que envolvem múltiplas sessões ao longo do tempo
- Quando o tom, o nível de formalidade ou o público-alvo são sempre os mesmos

O que pode ser injetado

Perfil pessoal ou profissional, estilo de escrita preferido, restrições fixas, público-alvo dos materiais produzidos, nível de detalhamento esperado e qualquer informação que você repetiria no início de cada nova conversa.

Antes — nova sessão, sem contexto:

> `*"Revise este parágrafo do meu artigo."*`

A IA não sabe: qual é a área? Qual o tom esperado? É um artigo acadêmico ou jornalístico? Para qual público?

Depois — com injeção de memória:

> `*"Contexto permanente desta sessão:*`
> `*— Sou estudante de Psicologia, 4º ano*`
> `*— Estou escrevendo um artigo acadêmico para uma revista nacional, normas ABNT*`
> `*— Tom: formal, objetivo, sem jargão clínico excessivo*`
> `*— Público: professores e pesquisadores da área*`
>
> `*Com base nesse contexto, revise o parágrafo abaixo:"*`

O bloco de contexto pode ser salvo em um arquivo de texto e colado no início de qualquer nova sessão. É uma prática simples que elimina repetições e torna as respostas muito mais ajustadas às suas necessidades.

6. Técnica 4 — Reverse Prompting / Prompt Reverso

Definição

Reverse Prompting (Prompt Reverso) inverte a lógica tradicional: em vez de você dar todas as instruções à IA, você pede que ela identifique o que precisa saber antes de executar a tarefa. O modelo atua como consultor que entrevista o cliente antes de agir.

Quando usar

- Tarefas complexas onde você mesmo não tem clareza total sobre o que quer
- Quando respostas anteriores foram genéricas demais por falta de especificidade
- Quando quiser usar a IA para ajudar a estruturar seu próprio pensamento antes de executar

Efeito colateral positivo

Além de melhorar a qualidade da resposta final, o Prompt Reverso frequentemente ajuda o próprio usuário a clarificar seus objetivos. As perguntas que a IA faz revelam lacunas que você não havia percebido — e que, se não preenchidas, levariam a um resultado insatisfatório.

****Antes:****

> **"Me ajude a melhorar minha apresentação de TCC."**

A IA dá dicas genéricas sobre apresentações em geral — sem saber nada sobre a área, a banca, o tempo disponível ou os pontos fracos específicos.

****Depois:****

> **"Atue como um orientador acadêmico experiente."**

>

> **"Antes de sugerir melhorias para minha apresentação de TCC, faça as perguntas necessárias para entender: área do curso, público da banca, tempo disponível para a apresentação, pontos que considero mais fracos e formato atual dos slides."**

>

> **"Só comece a sugerir melhorias depois de ter todas as informações."**

A IA entrevista você antes de agir. As sugestões que chegam depois são específicas para o seu caso — não para uma apresentação genérica imaginária.

7. Técnica 5 — Constrain Cascade / Cascata de Restrições

Definição

Constrain Cascade (Cascata de Restrições) consiste em fornecer instruções em camadas progressivas, uma de cada vez, em vez de entregar todas as instruções em um único bloco denso. Cada camada é confirmada antes da próxima ser adicionada.

Quando usar

- Tarefas longas e complexas com múltiplas etapas interdependentes
- Criação de documentos estruturados (planos, relatórios, roteiros)
- Quando erros no início de uma tarefa costumam comprometer todo o resultado

Por que funciona

Modelos de linguagem processam melhor instruções incrementais do que blocos de texto com muitas restrições simultâneas. Ao dividir a tarefa em camadas, você também ganha pontos de controle — pode corrigir o rumo antes que um erro se propague por toda a resposta.

****Antes — tudo de uma vez:****

```
> "Crie um plano de estudos para o ENEM cobrindo todas as matérias, com cronograma semanal, técnicas de memorização, simulados, revisão e dicas de redação, considerando que tenho 3 meses e estudo 2 horas por dia."
```

O resultado tende a ser longo, genérico e difícil de adaptar à realidade de quem perguntou.

****Depois — em cascata:****

****Mensagem 1:****

```
> "Vou criar um plano de estudos para o ENEM. Primeiro: liste apenas as áreas de conhecimento que precisam ser cobertas e confirme o entendimento."
```

****Mensagem 2 (após confirmação):****

```
> "Agora distribua essas áreas em 12 semanas, considerando 2 horas de estudo por dia, priorizando Matemática e Redação."
```

****Mensagem 3 (após nova confirmação):****

```
> "Para a semana 1, detalhe os tópicos diários e sugira um método de estudo adequado para cada um."
```

Cada etapa permite ajuste antes de avançar. O resultado final é muito mais preciso e utilizável do que um único bloco gerado de uma vez.

8. Técnica 6 — Verification Loop / Laço de Verificação

Definição

Verification Loop (Laço de Verificação) instrui a IA a executar um ciclo completo de autocrítica: gerar uma resposta, explicar o raciocínio por trás dela, criticar a própria explicação identificando limitações e inconsistências, e só então entregar a versão final corrigida.

Diferença em relação à Cadeia de Verificação

Enquanto a *Chain of Verification* foca na verificação de **fatos** (datas, nomes, dados), o *Verification Loop* foca no **processo de raciocínio** — verificando se a lógica da resposta é sólida, se as premissas são válidas e se as conclusões realmente decorrem dos argumentos apresentados.

Quando usar

- Análises e diagnósticos que envolvem múltiplas variáveis
- Recomendações que serão usadas como base para decisões importantes
- Respostas a perguntas abertas e complexas onde há risco de simplificação excessiva

****Antes:****

> **"Qual é a melhor estratégia para engajar alunos desmotivados?"**

A IA responde com confiança e diretamente — sem questionar se as premissas são válidas ou se as estratégias têm limitações contextuais.

****Depois:****

> **"Sugira três estratégias para engajar alunos desmotivados no ensino superior."**

>

> **"Para cada estratégia:"**

> **"1. Explique o raciocínio que a sustenta."**

> **"2. Critique a estratégia: quais são suas limitações e em que contextos ela pode não funcionar?"**

> **"3. Considerando as críticas, apresente a versão refinada da estratégia."**

A resposta final chega já auditada pelo próprio modelo. O processo de raciocínio fica visível, o que permite ao usuário identificar onde concorda ou discorda — e refinar ainda mais se necessário.

9. Técnica 7 — Técnica KERNEL

Definição

KERNEL é um framework estruturado para construir prompts completos, claros e reproduzíveis. Cada letra representa um princípio que, quando aplicado em conjunto, maximiza a qualidade e a consistência das respostas geradas.

Os 6 princípios

Letra	Princípio em inglês	Significado
K	<i>Keep it simple</i>	Mantenha simples — evite prompts longos e confusos
E	<i>Easy to verify</i>	Fácil de verificar — o resultado deve ser checável
R	<i>Reproducible</i>	Reproduzível — o mesmo prompt deve gerar resultados consistentes
N	<i>Narrow scope</i>	Escopo estreito — uma tarefa por vez, sem acumular pedidos
E	<i>Explicit constraints</i>	Restrições explícitas — diga o que não deve aparecer na resposta
L	<i>Logical structure</i>	Estrutura lógica — organize o prompt em blocos com função clara

Os 4 componentes da estrutura lógica

O princípio **L** (*Logical Structure*) se desdobra em quatro blocos que todo prompt bem construído deve contemplar:

Componente	Em inglês	Função	Pergunta que responde
Contexto	<i>Context</i>	Quem você é e qual é a situação	"Qual é o cenário?"
Tarefa	<i>Task</i>	O que exatamente deve ser feito	"O que fazer?"
Restrições	<i>Constraints</i>	Limites, exclusões e parâmetros	"O que não fazer ou como fazer?"
Formato de saída	<i>Format</i>	Como a resposta deve ser entregue	"Como apresentar?"

Um prompt KERNEL completo responde às quatro perguntas acima de forma explícita.

****Antes — sem estrutura KERNEL:****

```
> *"Me ajude a escrever um e-mail para o meu professor pedindo prazo."*
```

Sem contexto: a IA não sabe quem você é, qual é a relação com o professor, qual o motivo do pedido.

Sem restrições: a IA pode gerar um texto dramático, informal ou longo demais.

Sem formato: a IA pode entregar um parágrafo solto, sem estrutura de e-mail.

✓ **Depois — com estrutura KERNEL.**

> ****Contexto:**** Sou aluno de graduação em Letras, 3º semestre. Tive problemas de saúde na última semana que me impediram de concluir o trabalho a tempo.

>

> ****Tarefa:**** Escrever um e-mail formal solicitando uma extensão de 5 dias corridos para a entrega de um trabalho escrito.

>

> ****Restrições:**** Tom respeitoso e objetivo. Sem exageros dramáticos ou detalhes médicos. Máximo de 3 parágrafos. Não demonstrar que o prazo original foi esquecido.

>

> ****Formato:**** E-mail completo com linha de assunto, saudação formal, corpo em 3 parágrafos e despedida adequada.

O modelo sabe exatamente o que fazer – e o resultado está pronto para enviar, sem necessidade de edições.

Comparativo visual

Elemento	Antes	Depois (KERNEL)
Contexto	Ausente	Explícito
Escopo	Amplio e vago	Estreito e definido
Restrições	Nenhuma	Listadas
Formato esperado	Não especificado	Descrito em detalhes
Resultado	Genérico	Utilizável imediatamente

10. Boas Práticas Consolidadas

As sete técnicas apresentadas neste material compartilham um conjunto de princípios subjacentes. Internalizá-los transforma a relação com qualquer ferramenta de IA generativa:

Substitua adjetivos vagos por critérios mensuráveis.

Em vez de "texto criativo", diga "texto com no máximo 3 parágrafos, tom descontraído, sem jargão técnico". Em vez de "resposta completa", diga "resposta em formato de lista com 5 itens".

Defina o papel da IA antes de fazer o pedido.

Iniciar o prompt com "Atue como..." ou "Você é um especialista em..." enquadra a resposta de forma muito mais precisa do que começar diretamente com a tarefa.

Indique sempre o formato de saída esperado.

Lista, tabela, texto corrido, tópicos numerados, e-mail, roteiro — quanto mais claro o formato, menos ajustes serão necessários depois.

Itere: o primeiro prompt raramente é o melhor.

Engenharia de Prompts é um processo, não um ato único. A primeira resposta indica o que faltou no prompt — use isso para refinar a instrução e obter um resultado melhor na próxima tentativa.

Desconfie de respostas muito confiantes em temas factuais.

IAs generativas podem afirmar informações incorretas com alto grau de convicção. Para dados, datas, nomes e fatos que importam, sempre verifique em fontes primárias.

Uma tarefa por vez.

Prompts que pedem várias coisas ao mesmo tempo tendem a gerar respostas que resolvem mal cada uma delas. Quebre tarefas complexas em etapas menores — isso é o que a Cascata de Restrições formaliza.

11. Claude × ChatGPT: como as técnicas se aplicam

As sete técnicas funcionam em ambas as ferramentas, mas com nuances de comportamento que vale conhecer:

Técnica	Claude	ChatGPT
Few-Shot Prompting	Excelente adesão ao padrão fornecido	Bom, mas pode extrapolar além do padrão
Chain of Verification	Responde bem à instrução de autocrítica	Funciona melhor com instrução explícita e detalhada
Memory Injection	<i>Projects</i> (Projetos) mantêm contexto de forma nativa entre sessões	<i>Custom Instructions</i> ou memória automática (quando ativada)
Reverse Prompting	Comportamento natural — tende a perguntar antes de agir	Pode precisar de instrução mais direta para adotar o comportamento
Constrain Cascade	Lida bem com instruções longas e incrementais	Funciona melhor quando as mensagens individuais são curtas e diretas
Verification Loop	Forte em raciocínio explícito e estruturado	Bom desempenho, especialmente com modelos mais recentes
Técnica KERNEL	Segue a estrutura com fidelidade e precisão	Segue bem, mas tende a expandir mais além do solicitado

Observação: ambos os modelos evoluem continuamente. As características descritas acima refletem o comportamento observado nos modelos disponíveis à época deste material e podem mudar com novas versões. A melhor forma de aprender é experimentar as técnicas diretamente nas duas ferramentas.

Engenharia de Prompts não é programação — é comunicação intencional. As técnicas apresentadas aqui são ferramentas: a escolha certa depende da tarefa, do contexto e do resultado que você quer alcançar. O melhor prompt é sempre aquele que você itera até funcionar.